




数字员工的崛起

GPT-5.4 战略简报与白领工作流的重构

2025 战略技术与宏观经济洞察

从单一功能跨越至全能型数字基座



这是 OpenAI 首次将三大核心能力整合到单一模型。它不再是单一功能的强化，而是能在 ChatGPT、API 和 Codex 三大平台同步流转的全能型选手。

GPT-5.4 Thinking: 面向 ChatGPT 和 API 的通用主力。

GPT-5.4 Pro: 专为极端复杂任务打造的顶级算力模型。

突破系统边界的原生跨应用操作

OSWorld-Verified 成功率

75.0% GPT-5.4

72.4% 行业人类基准

47.3% GPT-5.2


Mainstay 真实商业案例：3 万个房产税门户数据处理



Step 1
全程截图驱动观察



Step 2
4 分钟内自动爬取
Zillow 旧金山房价



Step 3
跨应用导入 Google 表格



Step 4
坐标点击安排日历、发送邮件、
批量填写 10 个 Web 表单

首次尝试成功率达 95%（三次内达 100%）。任务完成速度提升 3 倍，Token 消耗大幅降低 70%。

视觉感知与浏览器接管引发知识工作重构



视觉引擎升级：支持 1024 万像素或 6000 像素最大边长的全保真感知输入。

“

对于知识型工作来说这是一场灭绝级别的事件。它能胜任所有浏览器工作，而且又准又便宜，即将引发一场白领革命。

— Sawyer Hood, 软件工程师

重新定义投行与律所的桌面生产力

GDPval 基准测试（涵盖美国 GDP 前 9 大行业的 44 种职业）：GPT-5.4 在 83.0% 的项目中达到或超越行业专业人类水平



金融与复杂建模

- 模拟初级投行分析师建模任务得分：87.3%（对比 GPT-5.2 的 68.4%）
- Walleye Capital 评估证实：内部财务评估准确率提升 30 个百分点



法律与长篇合同分析

- Harvey BigLaw Bench 测试准确率高达 91%
- 能在跨长篇合同中保持极高准确性，完美处理结构化复杂交易分析

复杂工程任务进入高可靠性区间

SWE-Bench Pro 得分：
57.7%

延迟断崖式下降：1800 秒
降至 500-800 秒

Codex Fast 模式：
提供 1.5 倍 Token 生成速度，
且保持同等智能水平

深层逻辑硬核测试验证


1. 成功对任天堂 NES ROM 进行逆向工程，拆解汇编逻辑。
2. 在从零构建编译器的极端测试中，迅速领会深层逻辑（Claude Code 卡死，GPT-5.3 极其吃力）。

HyperWrite CEO 评价：编码能力强得离谱，几乎完美无瑕。编码问题基本上已经解决了。

— Sawyer Hood, 软件工程师

一百万 Token 的算力边界与衰减曲线

模型能够一次性吞吐整个代码库、超长合同或海量科研文献，无需频繁压缩或分块。但在 MRCCR v2 测试中，精度随长度呈现明显的衰减。




战略洞察： 虽然拥有百万级吞吐量，但高精度的有效工作区间仍集中在 128K 以内。

工具调用架构升级重塑 Agent 经济学

Before / 旧模式



After / Tool Search 模式



MCP Atlas 基准测试（36 个服务器，250 个任务）：
在保持相同准确率的前提下，总 Token 消耗量骤降 47%。

Toolathlon 基准测试：在约 10 次工具调用让步时，
准确率达 55%（GPT-5.2 仅为 46%），使用更少的
交互轮次完成真实世界多步任务。

攻克“地狱级”基准的科研级推理

ARC-AGI-2:

GPT-5.4 Pro 达 83.3%
(前代仅 52.9%)

GPQA Diamond (研究生级) :

GPT-5.4 Pro 达 94.4%

FrontierMath Tier 4

(最高难度数学) :

GPT-5.4 Pro 达 38.0%
(翻倍超越前代的 18.8%)

CritPt

GPT-5.4 Pro


30.0% ★

Gemini 3.1
Pro Preview


17.7%

背景：被称为物理界的“地狱级”基准，2025 年顶尖模型多为个位数准确率。此次破纪录高分证明 AI 在辅助科研创新方面已具备极高实际价值。

思考过程透明化与事实性跃升



预先展示推理思路，允许用户在响应过程中实时调整方向，减少无效沟通往返。增强长上下文连贯性。



单个陈述错误率降低



完整回答中出现任何事实错误的概率降低

OpenAI 迄今为止事实性最强的模型，建立企业级部署的信任基础。

模型短板与安全边界的客观审视

短板与回退



HealthBench（健康问答）整体得分 62.6%，小幅低于前代的 63.3%。

Terminal-Bench 2.0（终端操作）得分 75.1%，略微逊色于 GPT-5.3-Codex 的 77.3%。

欺骗与监督



无诱导条件下整体欺骗率维持在约 1% 的极低水平。

未观测到主动对抗开发者监督的行为。

COT 可控性



模型难以被外部指令刻意改写思维链（COT）。

防止模型主动隐藏推理逻辑来绕过监控。

风险定级



被评为网络安全与生物化学领域的 **High 级高能力** 模型。

已部署双重防护体系以应对高级别风险。

智能的定价阶梯与算力成本考量

模型版本	输入 (每百万 Token)	输出 (每百万 Token)
GPT-5.4 Standard	\$2.5 (缓存 \$0.25)	\$15
(较前代输入成本上涨逾 40%)		
GPT-5.4 Pro	\$30	\$180

Hyperbolic CTO 金字晨的测试反馈：

“这是最过度思考的模型。一个简单的 Hi 思考了 5 分钟 18 秒，消耗了 80 美元（约 551 元人民币）。”

战略部署警告：Pro 版本算力极其昂贵，仅适用于最高复杂度的工程与科研突破，严禁用于轻量化交互场景。

梯次部署战略与旧模型的退役时间表

现已全线开放

- GPT-5.4 Thinking: 面向 ChatGPT Plus、Team 和 Pro 用户开放。
- GPT-5.4 Pro: 专属面向 Pro 和 Enterprise 计划用户。
- API 接入: 开发者现可通过 gpt-5.4 和 gpt-5.4-pro 接口全面调用。

遗留模型退役计划

原 GPT-5.2 Thinking 已移至遗留模型选择器。

最终退役日期: 2026 年 6 月 5 日

企业与开发者需在此日期前完成系统路由的全面升级与测试验证。

科技行业的结构性重组已经开始

科技岗位蒸发

过去一年累计净减少 5.7 万个。并非商业模式失败，而是利润暴增的同时，借助 AI 缩减了人力规模。



AI 与生产力激增

Citadel 数据显示软件开发向 AI 岗位激增转移。

范式转移：行业加速换人。“原来 5 个人的工作，现在 1 个人 + AI 就能完成。”
结构性失业将迅速由科技圈蔓延至投行、律所、咨询等传统白领领域。

纸面潜能正式转化为桌面生产力



两年的演进轨迹：从陪人聊天的“对话框”，到辅助敲代码的“副手”，再到今天直接接管鼠标键盘、接手复杂工作流的“数字员工”。那个曾经只会回答问题的 AI，已经悄无声息地坐上了我们的工位。

企业的核心竞争力，将从“拥有多少人类员工”彻底转变为“如何指挥你的数字员工”。