


DeepSeek Engram: 突破 Transformer 性能瓶颈的 全新架构

结合“条件记忆”与“条件计算”，
实现无损耗的参数无限扩展

JetBrains Mono


基于 DeepSeek 2024年1月12日发布的最新论文与开源实现



效率悖论：为何我们在用“深思熟虑”来处理“死记硬背”？

稀疏性（Sparsity）是当前大模型的核心设计原则（如 MoE），但现有的架构存在根本性缺陷。


- **异质性信号处理：**人类语言包含两类截然不同的信息——需要逻辑推理的“动态结构”与仅需检索的“静态知识”（如人名、地名、‘固定短语’）。
- **算力浪费：**Transformer 强行使用深层神经网络去模拟简单的记忆检索。
- **后果：**模型在早期层通过昂贵的计算重建静态知识，浪费了宝贵的模型深度与参数。



Engram: 引入“条件记忆” (Conditional Memory) 的第二维度

在条件计算 (MoE) 之外，DeepSeek 提出了互补的第二个稀疏维度。

- **参数无关 (Parameter-free)** : 外挂式的内化记忆库。
- **$O(1)$ 复杂度**: 将计算转化为查表。即刻找到答案，而非通过层层计算“算出”答案。
- **类比**: 就像不再每次心算 123×456 ，而是直接查乘法表。



架构概览：浅层部署与分工协作

Deep Layers: Attention Mechanism

- 专注于全局推理
- 长程依赖


Shallow Layers: Engram Active

- 接管局部依赖
- 静态知识存储


****浅层介入****：Engram 模块理想部署在网络的早期层。

****全局释放****：解放注意力机制（Attention），使其能专注于深层的全局推理。

核心技术 I：极高密度的信息压缩与哈希存储




128k 词表 -> 77k (减少 23%)



多头哈希 (Multi-head Hash) 近似大规模 N-gram 表，避免参数指数级增长

核心技术 II：上下文感知门控（Context-Aware Gating）

模型利用当前隐藏状态作为查询（Query）来评估检索内容的相关性。




■ 高激活（High Activation） - 注入外部知识

■ 抑制（Suppression） - 依靠逻辑推理

■ 抑制（Suppression） - 依靠逻辑推理


系统效率：零损耗的推理吞吐

- **确定性查表：**检索完全依赖于输入 Token，无需等待运行时状态，支持预取 (Prefetching)。
- **多分支集成：**利用矩阵乘法一次性处理多条并行分支，最大化 GPU 利用率。



缩放定律（Scaling Law）的新维度：无限内存

这是一个全新的 Scaling 手段——通过增大记忆容量可持续带来收益，且无需增加推理计算量。



实验背景：在 MoE 主干不变的情况下，单纯增加 Engram 的嵌入槽位数量。

资源分配的“黄金比例”

75%-80% MoE（条件计算）

负责动态计算与上下文理解

20%-25%
Engram
(条件记忆)


负责静态模式与知识存储

纯 MoE 的局限： 缺乏静态模式专用记忆，需反复重建，效率低。

纯 Engram 的局限： 失去动态计算能力，无法理解复杂上下文。

性能基准：更低的成本，更强的模型

训练计算量减少 18%（相比标准 MoE）




Engram-27B 在同参数下持续优于 MoE-27B 基线，释放了主干网络的推理能力。

长文本领域的统治力 (Long Context Mastery)

Context Window: 32,768 Tokens

Needle in a Haystack Accuracy: ~100%



机制：Engram 这种“局部依赖接管”机制，让 Attention 能够从琐碎的语法中解放出来，全力处理 32k 窗口下的全局模式。

结果：在 RULER 基准与多查询任务中大 幅领先同级 MoE。

消融实验：证明“知识”与“推理”的解耦

实验条件：在推理阶段强制屏蔽 Engram 模块输出。

事实性知识 (Factuality)



阅读理解 (Reading Comprehension)




结论：证明 Engram 有效隔离了“知识仓库”，而推理逻辑仍保留在主干网络中。

范式对比：Engram vs. RAG vs. 传统 MoE

	传统 MoE	RAG (检索增强生成)	DeepSeek Engram
知识位置 (Location)	模型参数内	外部数据库	内化记忆 (Internalized)
延迟 (Latency)	中 (路由开销)	高 (网络/检索)	极低 (O(1) 查表)
一致性 (Consistency)	不稳定 (训练难)	潜在冲突	强 (预训练固化)

未来展望：迈向“神经搜索引擎”



Future Directions

- **知识蒸馏：**将庞大的“知识库”与轻量级的“推理骨干”分离，实现模块化部署。
- **实时修正：**直接修改 Hash 表内数据来修正错误，无需昂贵的微调 (Fine-tuning)。
- **终极形态：**神经网络与智能检索引擎的有机结合体。

总结：重新定义稀疏性架构



降本增效

训练计算量降低 18%，
推理吞吐无损耗。



性能卓越

在长文本与逻辑推理任务
上全面超越传统 MoE。



无限扩展

解耦记忆与计算，开启了
通过堆叠内存提升智能的
新路径。

DeepSeek Engram 证明了——让上帝的归上帝（计算），让凯撒的归凯撒（记忆），
才是大模型进化的正确方向。